

ETL

Отчёт по финальной работе

Автор: Вальчук Денис

Глава I - Работа с Yandex DataTransfer

Первым этапом для исполнения данного задания потребовалось подготовить данные. Мной был сгенерирован датасет на более чем 60 Мбайт по структуре, предложенной в рамках задания (Забегая наперёд, я также воспользовался генерацией и для 2-ого с 3-им заданием). Код для генерации данных был опущен мной во всех 3-ёх заданиях, поскольку задания были явно посвящены иным темам (По этой причине, в последующих главах мной будет опущен пункт, связанный с генерацией данных).

Подготовив данных, я начал заниматься подготовкой конфигурации. У меня уже были приготовлены Object Storage, сервисный аккаунт и VPC, поскольку за них не взимается плата. Т.ч. потребовалось лишь включить NAT шлюз в таблице маршрутизации, а также создать БД Yandex DataBase.

Внутри БД мной была создана таблица со структурой, представленной в самом задании (Код в файле "create table.txt"), после чего я столкнулся с проблемой загрузки данных в таблицу. Я решил воспользоваться API Yandex Cloud и написать python скрипт для загрузки данных (Код в файле "insert data.py"). Но при загрузке датасета в таблицу я столкнулся с серьёзной проблемой – лимитом по request units.

Построковая загрузка является крайне накладной по RU, из-за чего я решил переписать загрузку через батчи по 100 строк каждый. Однако даже так, я достигал лимит через 1-2 тысячу строк. Это побудило поднять лимит в консоли Yandex Cloud, однако я всё равно его достигал через 10-20 тысяч записей. Даже полное отключение лимита не помогло – он всё равно меня настиг на 30-40 тысячах строк (А в датасете их 600 тысяч).

Поэтому пришлось пойти на серьёзный шаг, а именно поставить дилей на загрузку между батчами. Задержка была всего лишь 0.5 секунды, однако этого хватило чтобы растянуть загрузку данных в таблицу на целый час.

Загрузив данные, осталось лишь подготовить Data Transfer. Для этого нужно было подготовить эндпоинты из YDB в Object Storage и копирование данных пошло само собой. Результаты работы над данным заданием представлены в директории “Results”.

Глава II - Автоматизация работы с Yandex Data Processing при помощи Apache AirFlow

Поскольку общая инфраструктура уже была подготовлена за счёт первого задания, мне потребовалось лишь создать кластера Apache Hive Metastore , а также Managed Service for Apache Airflow. Оба кластера создавались с минимальными мощностями, дабы потратить как можно меньше средств.

Подготовив инфраструктуру, я принялся адаптировать задание Спарка к созданным мной датасетам (Код в файле "create_table.py"). В качестве задания, я решил объединить различные данные разного размера за 30 дней в один общий датасет.

Преобразовав задание и закинув его в Object Storage, я принялся дорабатывать ДАГ (Код в файле "dag.py"). Зная о нюансах квотирования, я сразу понизил мощности по дискам и ОЗУ у создаваемого кластера YDP.

Внеся все эти существенные корректировки, я запустил ДАГ и получил общий датасет в Object Storage.

Глава III - Работа с топиками Apache Kafka с помощью PySpark заданий в Yandex Data Processing

Как и в случае со вторым заданием, инфраструктура подготавливалась с минимальными мощностями. За основу PySpark заданий были взяты примеры из документации Yandex Cloud адаптированы для сгенерированного json файла. Примечательно, что потребовалось сгенерировать внушительный json на сотни Мбайт, т.к. после всех преобразований csv файл сильно уменьшался за счёт удаления json структуры.

Адаптировав задания, они были загружены в бакеты и успешно выполнены спарком. Единственным нюансом, с которым я столкнулся – это

была загрузка json'a в git hub. Поскольку он весил более 200 Мбайт, он, разумеется, не помещался в git push. Ввиду этой ошибки, поломался весь коммит из-за чего пришлось удалять локальный репозиторий вместе с изначальным json файлом. Т.ч. в git hub выложен не первоначальный json, а его новая итерация.

Глава IV - Визуализация в DataLens

Работа с DataLens оказалась приятным итогом всего этого задания. Датасеты были загружены в подключения, откуда я их перебросил в отдельную вкладку датасетов. Датасеты были специально загружены изначально в подключения, чтобы во вкладке “датасеты” я мог поиграться с их связями (К сожалению, из этого ничего не вышло).

Загрузив датасеты, я принялся за создания дашборда, после чего переключился на создание самих чартов для него. Поскольку данных были из файлов, я не стал углубляться в создание сложных чартов через QL или Editor и остановился на Wizard.

По каждому из датасетов мной было подготовлено несколько чартов:

- Задание 1:
 1. Круговая диаграмма по статусам звонков;
 2. Столбчатая диаграмма ответов клиентов в разрезе предложений.
- Задание 2:
 1. Гистограмма кредитов по продуктам (С разделением на одобренные и не одобренные кредиты);
 2. Линейный график заявок на кредиты (Всё также одобренные и нет).
- Задание 3:
 1. Линейный график средних сумм кредитов (по месяцам)ж
 2. Диаграмма уровня риска заёмщиков.